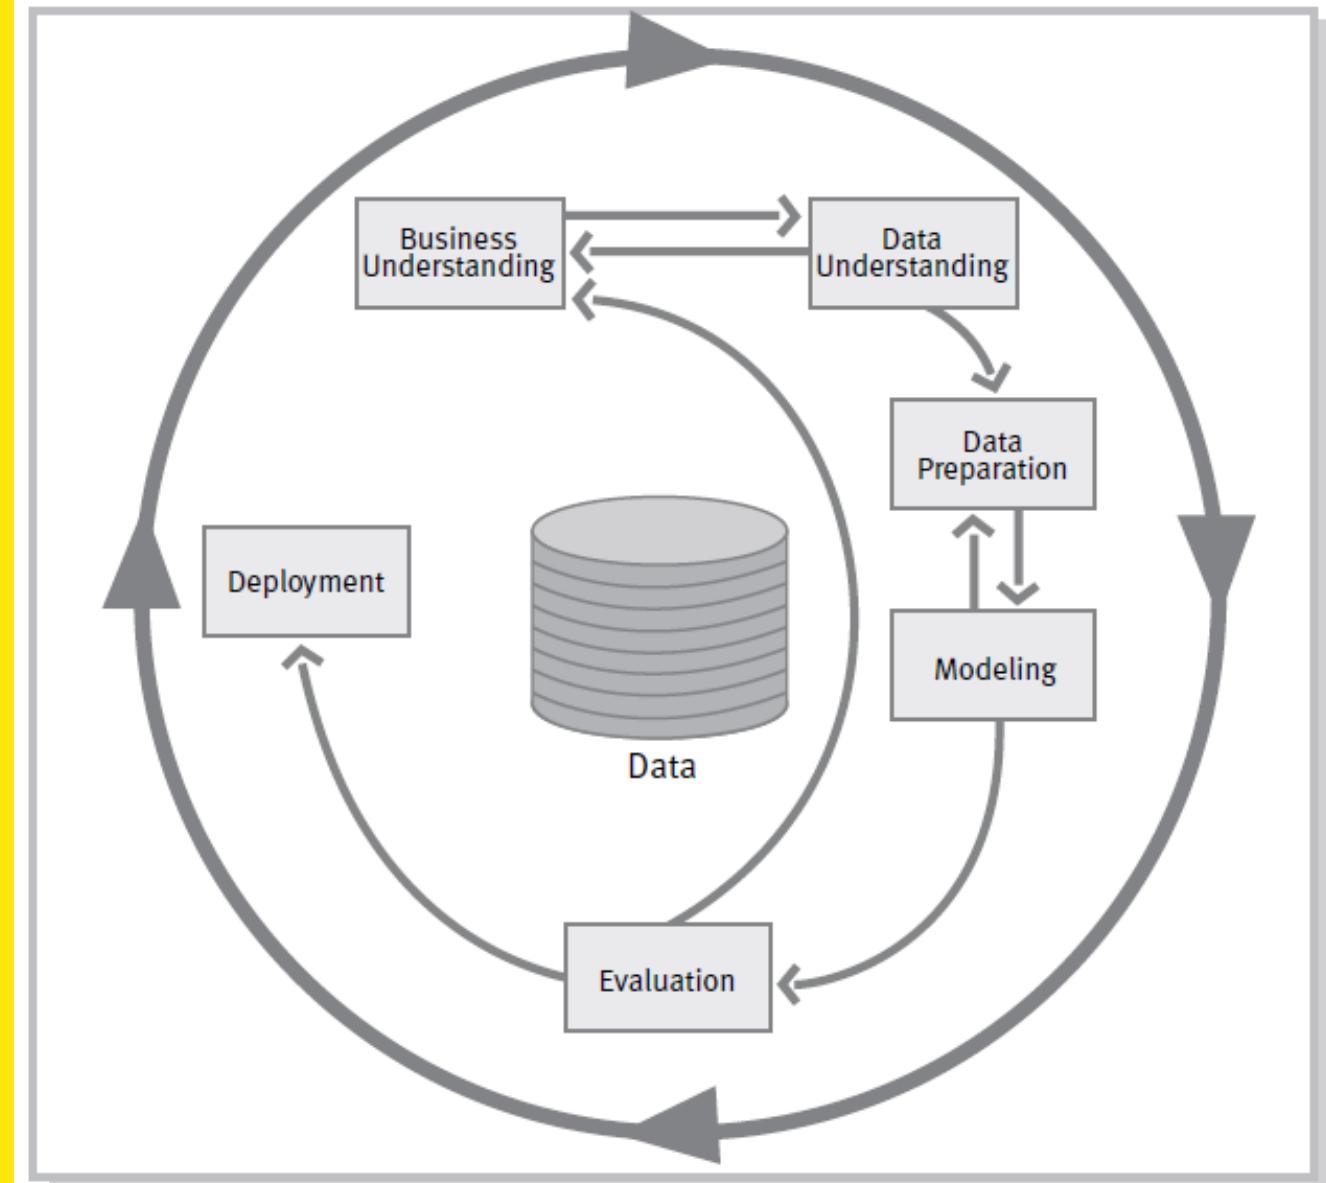


Maschinelles Lernen: Interpretierbarkeit

– Hans Friedrich Witschel, Andreas Martin

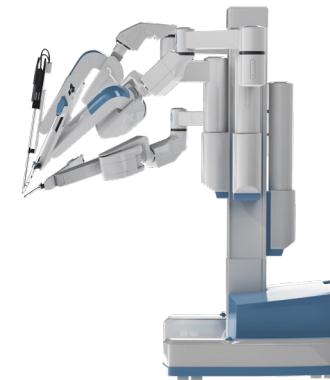


Interpretierbarkeit: Gedankenexperiment

- Stellt euch vor: ihr habt einen Tumor, der operiert werden muss
- Ihr habt 2 Optionen:



85% Überlebenschance



98% Überlebenschance

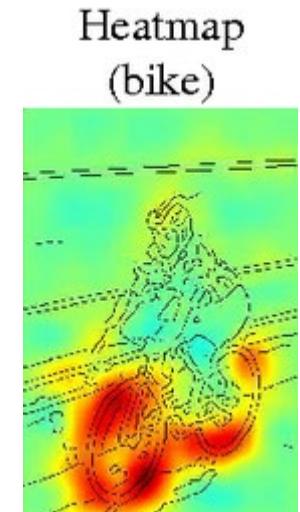
- Was wählt ihr?

Argumente für Interpretierbarkeit

1. Debugging, z.B.

- Data Leakage erkennen (Verwendung von Informationen, die zum Zeitpunkt der Vorhersage unbekannt sind)
- Umgang mit «Ausnahmefällen»

Machine learning models take on real-world tasks that require **safety measures** and testing. Imagine a self-driving car automatically detects cyclists based on a deep learning system. You want to be 100% sure that the abstraction the system has learned is error-free, because running over cyclists is quite bad. An explanation might reveal that the most important learned feature is to recognize the two wheels of a bicycle, and this explanation helps you think about edge cases like bicycles with side bags that partially cover the wheels.



- Unerwünschten Bias erkennen (Bsp.: Modell bevorzugt männliche Bewerber)
2. Vertrauen: Menschen sind meist verantwortlich für Entscheidungen
 3. (Wissenschaftliche) Erkenntnis, die aus Mustern gezogen werden kann

Arten von Interpretierbarkeit

Intrinsisch (Tree, LR, ...) \leftrightarrow post-hoc

modellspezifisch \leftrightarrow modell-agnostisch

lokal \leftrightarrow global

Intrinsisch interpretierbare Modelle

Lineare Modelle

(Lineare / logistische Regression, Naive Bayes, GLM, GAM)

Vorhersage = gewichtete Summe (von Log.)

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p + \epsilon$$



- Gut untersucht
- GAMs können nicht-lineare Effekte erfassen
- „geschmeidige“ Handhabung numerischer Features
- Wechselwirkungen zwischen Merkmalen werden nicht erfasst
- Erläuterung der Gewichte: geht immer davon aus, dass andere Merkmale unverändert sind
- Erweiterungen (z. B. GAMs) sind weniger interpretierbar

Logikbasierte Modelle

(Entscheidungsbäume / -tabellen, Regellerner)

Vorhersage = Menge logischer (Wenn-dann-)Regeln



- Wirklich einfache Interpretation
- Erfasst die Interaktionen zwischen den Merkmalen
- diskretisiert immer numerische Merkmale
- Instabil
- Grosse Bäume sind weniger interpretierbar

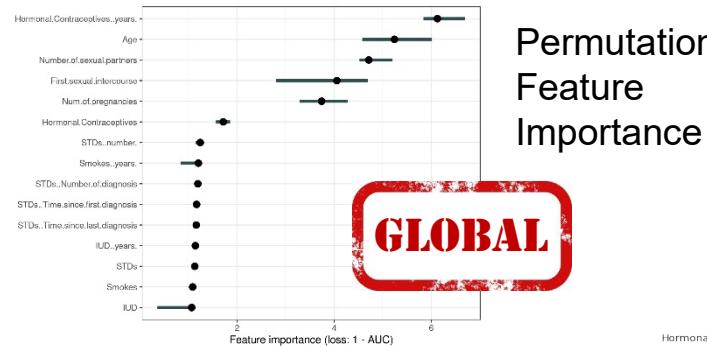
Nutzen bei: vielen numerischen Features



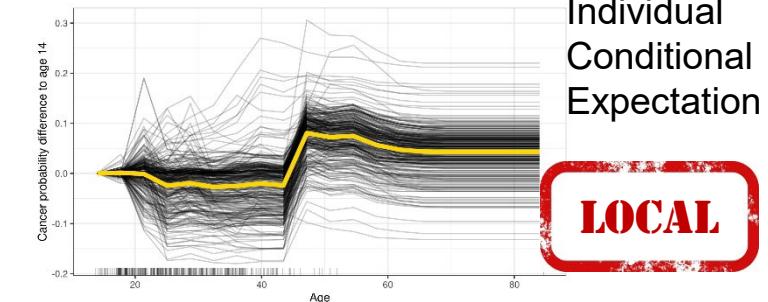
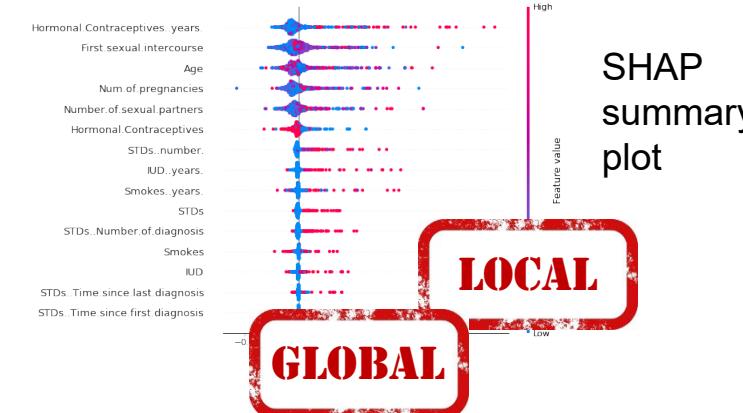
Nutzen bei: multivariaten Mustern

Interpretierbarkeit: Modell-agnostische post-hoc Ansätze

- Wie wichtig sind einzelne Features?



- Wie beeinflussen die Attributwerte die Vorhersage?



Ideen hinter den Ansätzen: Permutation Feature Importance

Idee:
Wichtigkeit eines Attributs = Anstieg des Fehlers, wenn die Information des Attributs durch Vertauschung der Attributwerte zwischen Instanzen zerstört wird



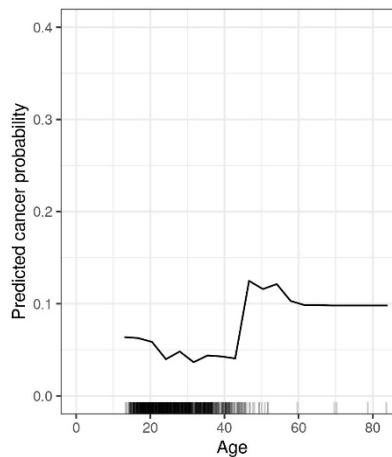
- Permutation zerstört auch die Interaktion eines Features mit anderen
→ Interaktionen, d.h. die Wichtigkeit von Features in Abhängigkeit von anderen wird berücksichtigt



- Benötigt Zugang zu den Labels der Daten
- Manchmal instabile (wegen randomisierter Permutationen)
- Permutationen können unrealistische Instanzen erzeugen (z.B. 2m grosse Person, die 30kg wiegt) → nicht unbedingt schlimm...
- Hinzufügen von Features, die mit vorhandenen stark korrelieren, verringern deren Wichtigkeit teils drastisch (nicht immer intuitiv...)

Ideen hinter den Ansätzen: Partial Dependence Plots

Idee:
Wert der PDP-Funktion für einen Attributwert = Durchschnittlicher Vorhersagewert des Modells, wenn alle Instanzen diesen Wert hätten

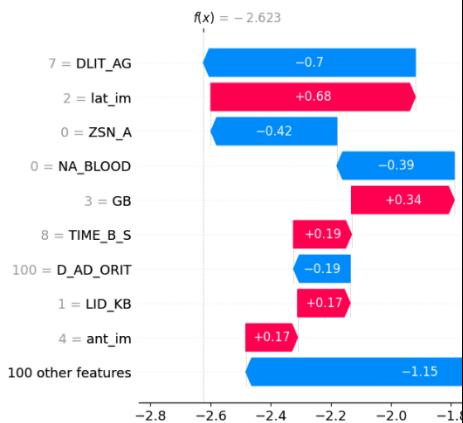


- intuitive Interpretation
- Kann als kausale Beziehung zwischen Feature-Wert und Vorhersage interpretiert werden (die laut dem Modell existieren!!!)



- Nur für 1 bis max. 2 Features
- Man sollte die Verteilung der Werte (an der x-Achse) in Betracht ziehen
- Ignoriert Korrelationen und Interaktionen von Features
- Bildung des Durchschnitts kann stark divergierende Werte verdecken (siehe ICEs)

Ideen hinter den Ansätzen: Shapley-Werte (lokal)



Idee:
Die Attributwerte einer Instanz betreten in zufälliger Reihenfolge einen Raum. Alle Attributwerte tragen zur Vorhersage bei.

Shapley-Wert eines Attributwerts = durchschnittliche Änderung der Vorhersage der "Koalition", wenn das Feature den Raum betritt.



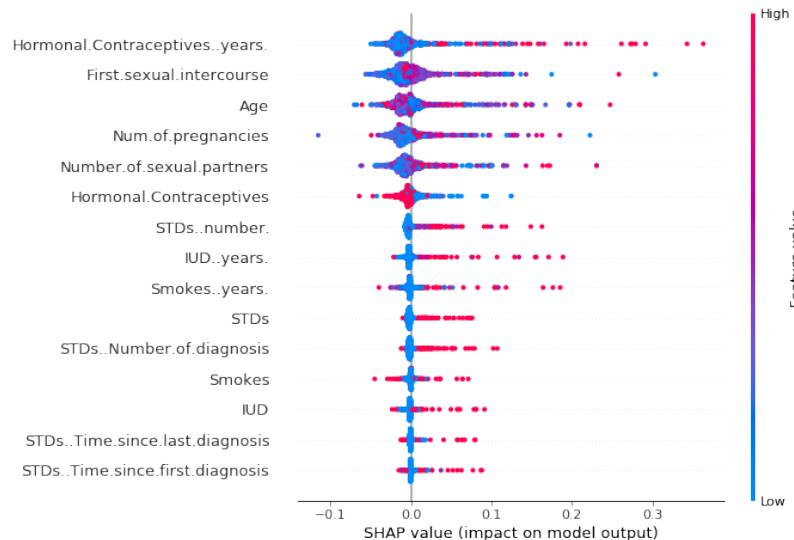
- Solide Theorie, kann vollständige Erklärungen liefern (im Gegensatz z.B. zu LIME)



- Rechenintensiv
- Nicht so einfach zu interpretieren
- Die Interpretation muss alle Merkmale berücksichtigen (und Menschen mögen kurze Erklärungen!!)

Genauere Erklärung:
<https://www.youtube.com/watch?v=VB9uV-x0gtg>
(bis 02:55 oder weiter...)

Ideen hinter den Ansätzen: SHAP Summary Plot (global)

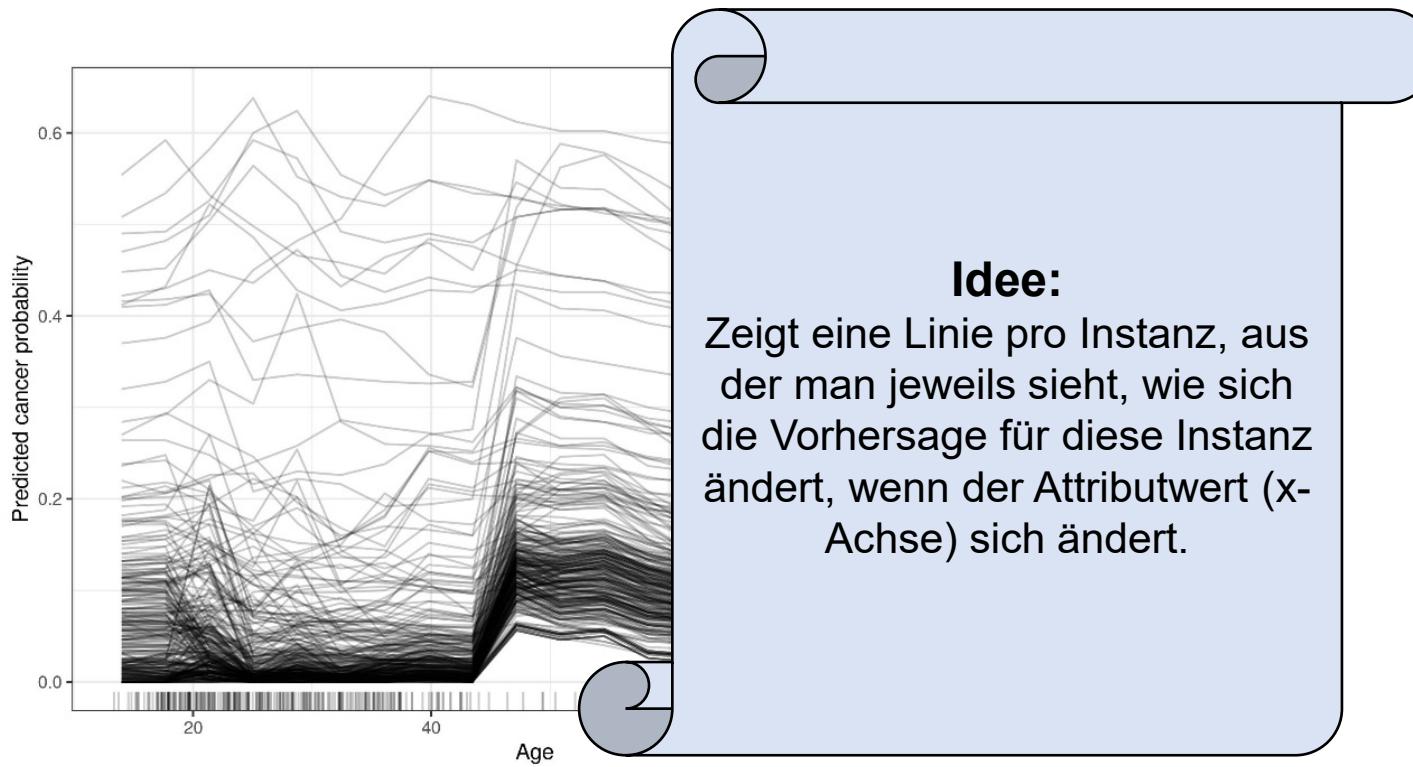


Idee:

Jeder Punkt ist ein Shapley-Wert für eine Instanz und ein Attribut. Attribute sind nach Wichtigkeit absteigend sortiert, Attributwerte farblich kodiert (rot = grosse Werte). Werte auf der x-Achse entsprechen der Vorhersage(wahrscheinlichkeit)

Ideen hinter den Ansätzen (3)

– Individual Conditional Expectation



- Zeigt mehr Details (Verteilung!) als PDPs
- Ziemlich intuitiv



- Nur 1 Feature darstellbar
- Bildet keine Interaktionen/Korrelationen ab

Interpretierbarkeit: Aufgabe 1. Teil

- **Hinweis:** Installiert zunächst das Add-on «Explain» in Orange und schaut euch die dort verfügbaren Widgets an...! Beachtet deren Input-Parameter!

1. **Globale Interpretation:** Wir arbeiten wieder mit den Daten der Firma «FixIt» aus dem Kapitel «Klassifikation»
 - a. Trainiert ein Gradient Boosting-Modell und prüft, ob es eine gute Performance hat bzw. konfiguriert es so, dass das der Fall ist! **Verwendet dabei zunächst alle Attribute.**
 - b. Welche Features sind generell am wichtigsten?
 - c. Wie lässt sich generell das Verhalten des Modells beschreiben? Wie genau hängen die Vorhersagen von den Werten der wichtigsten Features ab?
 - d. Kann man die «Target Leakage» erkennen?
 - e. Entfernt nun das Attribut «Days Open» und wiederholt die Schritte a-c! Erstellt einen «Steckbrief» des Modells, in dem ihr die Fragen b und c beantwortet!

Interpretierbarkeit: Aufgabe 2. und 3. Teil

2. **Vergleich** mit intrinsisch interpretierbaren Modellen: Vergleicht eure Interpretationen mit der Interpretation eines Entscheidungsbaums (von damals) und einer logistischen Regression.
 - a. Gibt es Unterschiede? Welche?
 - b. Was lässt sich mit den post-hoc-Methoden erreichen, was nicht? Ist das schlimm*?
3. **Lokale Interpretierbarkeit:**
 - a. Wählt ein Ticket aus, welches zu einer SLA Violation geführt hat, sowie eines, bei dem dies nicht der Fall war. (Tipp: um Instanzen auszuwählen, kann man das «Data Table»-Widget nutzen!)
 - b. Kreiert eine Erklärung für diese beiden Tickets und beschreibt sie in Worten!

* Was, wenn ihr z.B. ein Modell gelernt habt, das die Straffälligkeit von Personen vorhersagt, das zur Festsetzung von Strafen verwendet wird?