

|   |  |
|---|--|
| <b>Clustering</b>                                   | <p>"Ich sortiere Dinge so, dass Ähnliche zusammengehören."</p> <p>Wie wenn du Spielzeug sortierst:</p> <ul style="list-style-type: none"> <li>• Alle Legosteine zusammen</li> <li>• Alle Kuscheltiere zusammen</li> <li>• Alle Autos zusammen</li> </ul>   |
| <b>Dimensionsreduktion</b>                          | <p>Stell dir vor, du beschreibst eine Blume 🌸 mit 4 Eigenschaften:</p> <ul style="list-style-type: none"> <li>• Wie <b>lang</b> ist das Blatt?</li> <li>• Wie <b>breit</b> ist das Blatt?</li> <li>• Wie <b>lang</b> ist das Blütenblatt?</li> <li>• Wie <b>breit</b> ist das Blütenblatt?</li> </ul> <p>Das sind 4 Infos – man sagt auch: <b>4 Dimensionen</b>.</p> <p><b>Dimensionsreduktion bedeutet:</b></p> <p>"Ich versuche, das Wichtigste aus den 4 Eigenschaften in nur 2 oder 3 zusammenzufassen."</p> <p>So wie wenn du sagst:</p> <p>"Ich muss nicht alles wissen, es reicht, wenn ich nur das Wichtigste sehe."</p> |
| <b>Assoziation Rule Mining</b>                      | <p>Das ist ein Verfahren, mit dem der Computer herausfindet:</p> <p><b>Welche Produkte kaufen Menschen oft zusammen?</b></p> <p>Wenn jemand <b>Brot</b> kauft, dann kauft er vielleicht auch oft <b>Butter</b> dazu.</p>   |
| <b>Outlier Detection / Auffälligkeiten erkennen</b> | <p>Der Computer schaut Daten an und findet Datenpunkte, die ganz anders sind als der Rest. „<i>Finde die Daten, die nicht normal aussehen!</i>“ Damit man schnell reagieren kann!</p>  |
| <b>Früher Feature-based Machine Learning</b>        | <ul style="list-style-type: none"> <li>• Der Mensch musste <b>wichtige Merkmale</b> (z. B. Formen, Kanten) <b>von Hand rausziehen</b> (mithelfen)</li> <li>• Dann wurde damit ein Algorithmus trainiert (z. B. Entscheidungsbaum)</li> <li>• Beispiel: "Oh, das hat Streifen, vielleicht ein Tiger!"</li> </ul>  |
| <b>Heute Deep Learning</b>                          | <p><b>Heute (Deep Learning):</b></p> <ul style="list-style-type: none"> <li>• Der Computer <b>lernt die wichtigen Merkmale selbst</b></li> <li>• Er schaut sich <b>direkt die Pixel</b> an und erkennt selbst, was wichtig ist.</li> <li>• Das nennt man <b>Neuronales Netzwerk</b></li> </ul>   |
| <b>Clusteranalyse</b>                               | <p>Clusteranalyse ist wie "<b>automatisch Gruppen bilden</b>", der Computer sortiert Leute oder Dinge <b>nach Ähnlichkeiten</b> in Gruppen ein. „<i>Clusteranalyse findet heraus, wer ähnlich tickt – ganz ohne vorher zu wissen, wer zu wem gehört.</i>“</p>  |
| <b>Ziele Clusteranalyse</b>                         | <ul style="list-style-type: none"> <li>• Ähnliche Dinge in Gruppen einteilen (z. B. Personen, Produkte).</li> <li>• Man weiss <b>vorher nicht</b>, wie viele Gruppen es gibt – das findet der Computer raus.</li> <li>• Wird z. B. für <b>Marketing oder soziale Netzwerke</b> genutzt.</li> </ul>   |
| <b>Herausforderungen Clusteranalyse</b>             | <ul style="list-style-type: none"> <li>• Wie viele Gruppen soll man machen?</li> <li>• Manche Daten passen <b>nicht klar</b> in eine Gruppe.</li> </ul>  |
| <b>Nutzen</b>                                       | <ul style="list-style-type: none"> <li>• Hilft, Daten besser zu verstehen und <b>klügere Entscheidungen</b> zu treffen.</li> </ul>   |
| <b>Euklidische Distanz</b>                          | <p>Wie weit sind zwei Punkte voneinander entfernt?</p> <ul style="list-style-type: none"> <li>- Hilft Gruppen zu bilden (k-means)</li> <li>- Nützlich für: Nutzergruppen, Kaufverhalten, Medizin Muster</li> <li>- Macht Datenmengen übersichtlicher</li> </ul>  |

|   |  |
|---|--|
| <b>Datenauswahl &amp; Vereinfachung</b>               | „Die Auswahl repräsentativer Merkmale ist entscheidend für die Effektivität des Clusterings.“  |
| <b>Visualisierung im Streudiagramm (Scatter Plot)</b> | <ul style="list-style-type: none"> <li>- ermöglichen intuitive Einschätzung Datenstruktur</li> <li>- Label erleichtern Identifikation von Ausreißern &amp; Mustern</li> <li>- Liefern Anhaltspunkte für Bildung Cluster</li> <li>- Visualisierung mächtiges Werkzeug Hypothesenbildung</li> </ul>  |
| <b>Euklidische Distanz Berechnung</b>                 | <p>Misst direkten Abstand zwischen zwei Punkten</p> $\text{Euclidean Distance } (d) = \sqrt{(q_{x1} - p_{x1})^2 + (q_{x2} - p_{x2})^2}$  |
| <b>Anwendung Euklidischen Distanz Clustering</b>      | <ul style="list-style-type: none"> <li>- Bildet Fundament für quantitative Analyse Ähnlichkeiten</li> <li>- Erleichtert Dateninterpretation durch Bildung Gruppen</li> <li>- Anwendbar Kundenanalyse</li> </ul>  |
| <b>Hierarchisches Clustering</b>                      | <ul style="list-style-type: none"> <li>- Organisiert Datenpunkte Baumstruktur</li> <li>- Jeder Datenpunkt eigenständiges Cluster</li> <li>- Führt schrittweise nahe Cluster zusammen</li> <li>- Wahl Distanzmasses beeinflusst Clusterstruktur</li> </ul>  |
| <b>Distanzmasse Single Linkage (Nächster Nachbar)</b> | <ul style="list-style-type: none"> <li>- Schaut sich den kürzesten Abstand zwischen zwei Punkten aus unterschiedlichen Gruppen an.</li> <li>- Wenn zwei Punkte sehr nah sind, verbindet es die Gruppen.</li> <li>- Kann dabei lange „Ketten“ bilden – auch wenn der Rest gar nicht so nah beieinander ist.</li> <li>- Empfindlich bei Ausreißern.</li> </ul> <p>Gut, wenn man nicht-kreisförmige Gruppen erkennen will.</p>  |
| <b>Distanzmasse Average Linkage (Durchschnitt)</b>    | <ul style="list-style-type: none"> <li>- Rechnet den durchschnittlichen Abstand zwischen allen Punkten zweier Gruppen.</li> <li>- Dadurch entstehen sauberere Gruppen – eher kompakt und gut getrennt.</li> <li>- Weniger empfindlich gegenüber Ausreißern.</li> <li>- Gibt oft bessere, gleichmässige Ergebnisse.</li> </ul>  |
| <b>Distanzmasse Ward Linkage</b>                      | <p>Ward Linkage sorgt dafür, dass die <b>Gruppen möglichst "sauber"</b> bleiben. Das heißt: Die Punkte in einem Cluster sollen <b>nah beieinander liegen</b> (wenig Streuung).</p> <p><b>Wie funktioniert das?</b></p> <ul style="list-style-type: none"> <li>• Es schaut: <b>Welche zwei Gruppen kann ich verbinden</b>, ohne dass die Punkte zu unterschiedlich werden?</li> <li>• Ziel: Die Punkte in einem Cluster <b>sollen sich möglichst ähnlich sein</b>.</li> </ul> <p><b>Vorteile:</b></p> <ul style="list-style-type: none"> <li>• Macht <b>runde, kompakte Gruppen</b>, die gut getrennt sind.</li> <li>• Funktioniert gut für viele reale Anwendungen.</li> <li>• Ist wie ein <b>Kompromiss</b> zwischen "nächster Punkt" (Single Linkage) und "Durchschnitt" (Average Linkage).</li> </ul> |
| <b>Visualisierung Dendrogramm</b>                     | Baumartige Diagrammstruktur, die die Bildung von Clustern visualisiert. Man kann gut sehen welche Dinge zusammengehören.   |
| <b>Hierarchisches Clustering Interpretation</b>       | <ul style="list-style-type: none"> <li>- Detaillierte Einsicht in Datenstruktur &amp; mögliche Cluster</li> <li>- Wie viele Cluster entscheidet «Experte»</li> <li>- Kann multidimensionale Daten erweitern</li> <li>- Visualisierung Cluster im Streudiagramm</li> <li>- Dendrogramm mächtiges Werkzeug Visualisierung</li> </ul>   |
|   |  |

|  |  |
|--|--|
| <b>Hierarchisches Clustering in höheren Dimensionen</b>        | <p>Mehrdimensionales Clustering ermöglicht Analyse komplexerer Daten. Die Abstände (Distanzen) zwischen Datenpunkten werden mit einer erweiterten Formel berechnet, je mehr Dimensionen desto länger Formel. <b>Problem:</b> zu viele Dimensionen machen die Analyse schwieriger. Das nennt man den <b>Fluch der Dimensionalität</b>.</p> $d = \sqrt{(q_{x1} - p_{x1})^2 + (q_{x2} - p_{x2})^2 + (q_{x3} - p_{x3})^2 + \dots}$                   |
| <b>Fluch der Dimensionalität</b>                               | <ul style="list-style-type: none"> <li>- Je mehr Eigenschaften (Dimensionen) Daten haben, desto grösser wird Raum.</li> <li>- Abstände zwischen Datenpunkten sagen weniger aus</li> <li>- Muster zu finden schwieriger</li> <li>- Clustering funktioniert schlechter</li> <li>- Lösung: Daten gut vorbereiten und normalisieren</li> </ul>   |
| <b>Euklidisch vs. Cosinus-Distanz (bei vielen Dimensionen)</b> | <p><b>Euklidische Distanz:</b> misst den direkten Abstand zwischen zwei Punkten, in hohen Dimensionen alle Abstände ähnlich.</p> <p><b>Cosinus-Distanz:</b> misst Winkel zwischen zwei Punkten (Vektoren), funktioniert besser in vielen Dimensionen, da sie Richtung statt Abstand betrachtet, nützlich bei Textdaten.</p>  |
| <b>k-Means Clustering</b>                                      | <ul style="list-style-type: none"> <li>- Teilt Daten in vorgegebene Anzahl k an Gruppen</li> <li>- Ziel: ähnliche Datenpunkte in eine Gruppe zu packen</li> <li>- Braucht k als Startwert (wie viele Gruppen?)</li> <li>- Gut wenn keine Vorkenntnisse über Datenkategorien hat</li> </ul>   |
| <b>k-Means Algorithmus Schritt 1 Initialisierung</b>           | <ul style="list-style-type: none"> <li>- Algorithmus startet mit zufälligen Mittelpunkten</li> <li>- Startpunkte beeinflussen Endergebnis &amp; wie schnell Algorithmus konvergiert</li> <li>- Wahl Mittelpunkte wichtig</li> </ul>  |
| <b>Schritt 2 Zuordnung Clustern</b>                            | <ul style="list-style-type: none"> <li>- Jeder Punkt wird nächsten Mittelpunkt zugeordnet</li> <li>- Dafür verwendet man euklidische Distanz</li> <li>- So entsteht erste Gruppierung Daten</li> <li>- Basis für Berechnung Mittelpunkte</li> <li>- Wird in jedem Schritt neu berechnet, um Cluster verbessern</li> </ul>  |
| <b>Schritt 3 Mittelpunkte aktualisieren</b>                    | <ul style="list-style-type: none"> <li>- Neuen Mittelpunkte werden als Durchschnitt Punkte in jedem Cluster berechnet</li> <li>- Ziel: Cluster verbessern Gruppen kleiner machen</li> <li>- Mittelpunkte verschieben sich, um besser zu passen</li> <li>- Macht Cluster einheitlicher (homogener)</li> <li>- Schritt wird mehrmals wiederholt bis nichts mehr ändert</li> </ul>  |
| <b>Schritt 4 Wiederholen &amp; Prüfen</b>                      | <ul style="list-style-type: none"> <li>- Schritt 2 &amp; 3 wiederholt sich bis nichts mehr verändert</li> <li>- Dann gilt: Cluster sind stabil = Konvergenz erreicht</li> <li>- Algorithmus stoppt wenn alles stabil ist oder eine maximale Anzahl Wiederholungen erreicht wurde</li> <li>- Wiederholungen machen Cluster genauer und besser</li> <li>- Manchmal mehrere Durchläufe mit anderen Startpunkten nötig für gutes Ergebnis</li> </ul> |
| <b>Einfluss k (Anzahl der Cluster)</b>                         | <ul style="list-style-type: none"> <li>- K = 2 (Daten in 2 grosse Gruppen aufteilen)</li> <li>- K = 4 (Daten in 4 feinere Gruppen aufteilen)</li> </ul> <p>Zu viele Cluster = zu kleinteilig<br/> Zu wenige Cluster = wichtige Unterschiede gehen verloren<br/> Richtige Anzahl Cluster finden entscheidend</p>  |

## Unsupervised Learning

|   |  |
|---|--|
| <b>Vorteile k-Means gegenüber hierarchischem Clustering</b> | <ul style="list-style-type: none"><li>- Schneller &amp; effizienter bei grossen Datenmengen</li><li>- Weniger Speicherbedarf</li><li>- Schnelle Ergebnisse</li><li>- Gut für runde (sphärische) Gruppen</li><li>- Einfach anpassbar</li></ul>  |
| <b>Herausforderungen schwierigen Daten</b>                  | <p>Richtige Anzahl Cluster (K) nicht eindeutig, ergebnis abhängig von Startpunkten &amp; Probleme entstehen, wenn:</p> <ul style="list-style-type: none"><li>- Ausreisser</li><li>- Cluster sich überlappen</li><li>- Cluster keine runde Form haben</li></ul> <p>Dann kann k-Means falsche Gruppen bilden</p>   |
| <b>DBSCAN</b>   | <p>Density-Based Spatial Clustering of Applications with Noise</p> <ul style="list-style-type: none"><li>- Findet Cluster, wo viele Punkte beieinander liegen</li><li>- Keine Angabe Clusteranzahl nötig</li><li>- Erkennt Ausreisser</li><li>- Gut für komplizierte Formen &amp; unterschiedliche Dichten in Daten</li></ul>                                |
| <b>DBSCAN wichtige Punktarten</b>                           | <p><b>Kernpunkte:</b> haben genug Nachbarn &amp; bilden Zentrum Cluster</p> <p><b>Randpunkte:</b> wenige Nachbarn, sind aber nahe bei Kernpunkten</p> <p><b>Rauschen:</b> Punkte die weit weg sind, gehören zu keinem Clustern</p>   |
| <b>Word Clustering</b>                                      | <ul style="list-style-type: none"><li>- Wörter werden als Zahlen-Vektoren dargestellt (Word Embeddings).</li><li>- Ähnliche Wörter haben ähnliche Vektoren</li><li>- Ziel: Thematisch ähnliche Wörter gruppieren</li><li>- Dafür wird Cosinus-Distanz zur Messung ähnlichkeit genutzt</li><li>- Hierarchisches Clustering macht daraus Dendrogramm</li></ul> |
| <b>Word Clustering mit t-SNE</b>                            | <ul style="list-style-type: none"><li>- <b>t-SNE</b> zeigt Wörter, dass ähnliche <b>Wörter beieinander</b></li><li>- jeder <b>t-SNE-Plot</b> ist ein Wort</li><li>- so kann man Cluster visuell prüfen</li><li>- <b>t-SNE</b> kann ungewöhnliche Wörter sichtbar machen, die nicht richtig passen</li></ul>  |